


Knowledge Graph

Từ lý thuyết đến ứng dụng

Khái niệm · Property Graph · Schema · Suy diễn · Cypher
Nghiên cứu tình huống: đồ thị tri thức phim đa nguồn



Học viên


Hoàng Kim Khánh · 20252307M

Giảng viên hướng dẫn

TS. Trần Ngọc Thắng

Từ dữ liệu đến tri thức có thể sử dụng


Knowledge Graph không chỉ lưu giá trị; nó đặt giá trị vào ngữ cảnh, quan hệ và ngữ nghĩa.



Ngữ cảnh + quan hệ + quy tắc làm cho dữ liệu trở thành tri thức có thể truy vấn và suy luận.

Knowledge Graph là gì?

Một mô hình tri thức dạng đồ thị, trong đó thực thể và quan hệ mang ngữ nghĩa có thể đọc bởi cả người và máy.



N Thực thể (entity)

Đối tượng có định danh: người, phim, địa điểm, tổ chức...

E Quan hệ (relationship)

Liên kết có nghĩa và có hướng giữa các thực thể.


P Thuộc tính & định danh

Tên, ngày, rating... mô tả node/cạnh; ID phân biệt identity.


Schema nói điều gì được phép; instance nói điều gì đang đúng

Tách lớp khái niệm khỏi dữ liệu cụ thể giúp kiểm tra tính nhất quán và tái sử dụng mô hình.


LỚP KHÁI NIỆM · TBOX / SCHEMA



Domain: Person · Range: Movie



LỚP SỰ KIỆN · ABOX / INSTANCE



1

Graph schema
Định nghĩa label, thuộc tính, quan hệ, ràng buộc.

2


Knowledge base
Schema + tập instance/fact đang lưu.

3

Knowledge Graph
Knowledge base được tổ chức và truy vấn như đồ thị.

Property Graph biểu diễn trực tiếp node, cạnh và thuộc tính

Đây là mô hình graph duy nhất được triển khai trong project.



Node

Movie, Person, Genre, Keyword và Studio.



Relationship

ACTED_IN, DIRECTED, HAS_GENRE...



Property

Node và cạnh đều mang dữ liệu; cạnh ACTED_IN giữ vai diễn và thứ tự cast.

Cypher vừa truy vấn mẫu đường đi, vừa vật chất hóa luật nghiệp vụ

Một ngôn ngữ thống nhất cho constraint, traversal, aggregation và derived relationship.

Truy vấn bằng pattern

```
MATCH (p:Person)-[:DIRECTED]->(m:Movie)
WHERE p.name = $name
RETURN m.title
```

Pattern thể hiện trực tiếp node và cạnh cần tìm; giá trị người dùng được truyền bằng parameter.

Suy diễn bằng rule

```
MATCH (a)-[:ACTED_IN]->(m)<-[:ACTED_IN]-(b)
MERGE (a)-[:CO_STARRED_WITH]->(b)
```

Fact suy ra lưu movie_count, evidence_movie_ids và derived=true để kiểm chứng.

Không có reasoner riêng: luật nghiệp vụ được khai báo và thực thi trực tiếp trong Neo4j.

Movie Knowledge Graph là nơi các khái niệm được kiểm chứng

THỰC THỂ

Movie · Person ·
Genre · Keyword ·
Studio

QUAN HỆ

ACTED_IN · DIRECTED ·
HAS_GENRE...

ĐỊNH DANH

Stable TMDB/IMDb
IDs + provenance

SUY DIỄN

CO_STARRED_WITH có
bằng chứng

TRUY VẤN

Cypher có tham số

Phần sau: bài toán → kiến trúc → dữ liệu → ứng dụng → bằng chứng thực nghiệm

Neo4j được chọn vì phù hợp với quan hệ và traversal

Giá trị của đồ thị nằm ở mô hình quan hệ và đường đi bằng chứng — không phải luôn nhanh hơn SQL.

Yêu cầu	Mô hình bảng	Đồ thị thuộc tính
Quan hệ nhiều-nhiều	Bảng nối	Cạnh trực tiếp
Truy vấn nhiều bước	Chuỗi JOIN	Mẫu đường đi
Suy diễn co-star	Logic vật chất hóa riêng	Cạnh suy ra có bằng chứng
Giải thích	Dựng lại quan hệ	Đường đi tự nhiên

Neo4j / Cypher


Kho vận hành cho duyệt đồ thị, hỏi-đáp và gợi ý.

Property-rich relationships

Cạnh ACTED_IN và CO_STARRED_WITH mạng thuộc tính và bằng chứng trực tiếp.


Kiến trúc đầu cuối: từ nguồn đến bằng chứng

Sau khi import, đường chạy trình diễn không phụ thuộc Internet.



Tích hợp IMDb theo chiến lược tiết kiệm lưu trữ

Chỉ đọc tuần tự tệp rating nén và ghép chính xác theo IMDb ID; không tải toàn bộ IMDb vào đồ thị.



4.558

Movie có IMDb ID

4.351

Rating ghép chính xác

95,5%


Tỷ lệ ghép trên IMDb ID

Không ghi đè

`rating`, `imdb\_rating` và `imdb\_votes`
được giữ riêng.

Mô hình dữ liệu đặt định danh lên trước tên gọi

Một Person có thể vừa là diễn viên vừa là đạo diễn; vai trò được biểu diễn bằng quan hệ.



Định danh ổn định

`Person.person\_id = tmdb:<id>`
Tên không phải khóa chính.

Vai trò trên cạnh


`ACTED\_IN` giữ character, cast_order và source.

Ràng buộc

Ràng buộc (constraint) và chỉ mục được tạo trước khi nhập dữ liệu.

Quy trình dữ liệu có thể chạy lại và kiểm tra

Raw cache bất biến → dữ liệu chuẩn hóa tất định → import idempotent → validation.



Cache

Không tải lại nguồn khi xử lý lại

Manifest

Count + checksum + chất lượng

MERGE

Import lặp không nhân bản

Gate

Phát hiện orphan và khóa lỗi

Đồ thị cuối cùng vượt qua toàn bộ quality gate

Một bản ghi Movie không có quan hệ bị loại; ảnh chụp hợp lệ còn 4.999 phim.

76.612

Tổng số nút

846.309

Tổng số quan hệ

53.555

Person

12.509

Keyword

5.530

Studio

0

vi phạm cấu trúc



Orphan Movie



Stable ID trùng




Thiếu thuộc tính bắt buộc



Cạnh sai kiểu/đầu mút

Phân giải thực thể: exact trước, fuzzy có kiểm soát

Mục tiêu là tránh false positive; trường hợp mơ hồ có thể từ chối thay vì nối sai.



1,000

Precision

100 cặp silver

0,933

Recall

5 trường hợp abstain

0,966

F1

nearest-name hard negatives

Nguồn: entity_resolution.json · sơ đồ: report_latex/images/sources/entity_resolution_flow.drawio

Cypher biến câu hỏi quan hệ thành mẫu đường đi

Tham số người dùng được truyền riêng; cấu trúc truy vấn lấy từ danh mục cố định.

```
MATCH (d:Person)-[:DIRECTED]->(m:Movie)
      -[:HAS_GENRE]->(g:Genre)
WHERE g.name = $genre
RETURN d.name, count(m) AS movie_count
ORDER BY movie_count DESC
LIMIT $limit
```

`$genre` · `$limit`



Tra cứu

Phim theo đạo diễn · diễn viên theo phim



Nhiều bước (multi-hop)

Phim chung · đạo diễn → phim → thể loại



Đường đi và suy diễn

`shortestPath([*..8])` · `CO_STARRED_WITH`




An toàn

Không nối chuỗi đầu vào vào Cypher.

CO_STARRED_WITH là fact suy ra có thể kiểm chứng

Đây là phép vật chất hóa luật nghiệp vụ bằng Cypher.



Sự kiện được khẳng định

ACTED_IN đến từ danh sách vai diễn của TMDB.

Sự kiện suy ra

CO_STARRED_WITH được tạo từ phim chung.


Bằng chứng

movie_count · evidence_movie_ids · derived=true

Nguồn chỉnh sửa: report_latex/images/sources/costar_reasoning.drawio

Giá trị của chatbot nằm ở việc điều phối Cypher an toàn

Ngôn ngữ tự nhiên chọn ý định và thực thể; Neo4j thực hiện traversal và trả bằng chứng.



9 ý định cố định

Tra cứu · tổng hợp · nhiều bước · đường đi ngắn nhất

Liên kết thực thể

“Cristopher Nolan” → Christopher Nolan + độ tin cậy

Bảng chứng đồ thị

Ý định · thực thể · bản ghi/đường đi · độ trễ

Nguồn chỉnh sửa: report_latex/images/sources/qa_sequence.drawio

Gợi ý giải thích được bằng đóng góp trên đồ thị

IDF giảm ảnh hưởng của đặc trưng quá phổ biến; mỗi đề xuất kèm các đặc trưng chung tạo điểm.



$\text{contribution} = \text{type_weight} \times (1 + \ln((N+1)/(df+1)))$

Đạo diễn		3,0
Diễn viên		2,0
Thể loại		1,5
Từ khóa		1,0

Điểm được tính trong Neo4j
Không tải toàn bộ graph về Python.

Nguồn chỉnh sửa: report_latex/images/sources/recommendation_explanation.drawio

Đánh giá được thiết kế theo từng tuyên bố

Mỗi metric gắn với dataset, protocol và giới hạn diễn giải cụ thể.

Hạng mục	Tập đánh giá	Metric
Chất lượng dữ liệu	Toàn corpus	missing · duplicate · orphan
Phân giải thực thể	100 cặp silver	P · R · F1
Suy diễn co-star	50 fact silver	precision
Hỏi–đáp	20 câu smoke	accuracy + evidence
Gợi ý	20 case silver	P@10 · NDCG@10
Hiệu năng	4 quy mô × 4 query	median · p95 · 100 lần

Silver ≠ ground truth độc lập

Corpus được sinh tất định, có provenance và rubric công bố.

So sánh công bằng

Neo4j và SQLite dùng cùng snapshot, máy, warm-up và số lần chạy.



Không vượt quá bằng chứng

Không suy rộng sang concurrency, cold cache hay production scale.

KẾT QUẢ

Kết quả chính: đúng cấu trúc, có bằng chứng, còn dư địa cải thiện

Các con số dưới đây đều thuộc lần chạy 5.000 đầu vào ngày 24/07/2026.



Cách đọc thận trọng


- QA là smoke corpus được quản lý.
- Entity precision cao nhờ abstention bảo thủ.
- Recommendation là metric silver, chưa phải đánh giá người dùng.
- Mọi output gợi ý đều có đường giải thích.

Nguồn: experiments/results/summary/quality_metrics.csv


Phép đo so sánh cho thấy sự đánh đổi

SQLite nhanh hơn ở toàn bộ cặp truy vấn/quy mô; Neo4j đổi lại mô hình duyệt đồ thị và bằng chứng trực tiếp.

Median latency · common_movies (ms)



Lịch sử thiết kế ranker · 20 case




Kết luận hiệu năng

Đo warm-cache, 100 lần/query, không đo concurrency hoặc cold cache.

Kết luận gợi ý


Các mốc cũ là lịch sử thiết kế, không phải lựa chọn runtime.

Từ câu hỏi tự nhiên đến đường đi bằng chứng



Giới hạn được xem là một phần của kết quả

Các kết luận chỉ có giá trị trong ảnh chụp dữ liệu và protocol đã công bố.



Đồ thị tri thức tạo giá trị khi mỗi quan hệ đều có thể được kiểm chứng

01

Tích hợp đúng

TMDB + IMDb, stable ID, provenance
và quy trình tái lập.

02

Truy vấn được

Cypher multi-hop và derived fact có
bằng chứng.

03

Giải thích được

QA và gợi ý trả cả thực thể, path và
đóng góp điểm.

Xin cảm ơn thầy. Em xin lắng nghe câu hỏi và phản biện.