


Xây dựng đồ thị tri thức phim đa nguồn

Tích hợp dữ liệu · Truy vấn nhiều bước · Suy diễn · Hỏi–đáp và gợi ý có bằng chứng



Học viên


Hoàng Kim Khánh · 20252307M

Giảng viên hướng dẫn

TS. Trần Ngọc Thăng

Dữ liệu phim vốn là một mạng quan hệ

Tra cứu một bảng không đủ khi câu hỏi đi qua nhiều thực thể và nhiều nguồn.



1

Quan hệ dày đặc

Movie kết nối Person, Genre, Keyword và Studio theo cấu trúc nhiều-nhiều.

2

Nguồn phân tán

TMDB cung cấp metadata/credits; IMDb cung cấp rating và số lượt đánh giá độc lập.

3

Cần bằng chứng

Câu trả lời và gợi ý phải chỉ ra thực thể, quan hệ hoặc đường đi đã tạo nên kết quả.

Ba khoảng trống cần giải quyết đồng thời

Nếu thiếu một trong ba, hệ thống có thể trả lời được nhưng không đáng tin hoặc không giải thích được.

Định danh đúng

209 người trùng tên vẫn phải là các thực thể khác nhau.

Không dùng tên làm khóa chính; ưu tiên định danh nguồn ổn định.

Duyệt nhiều bước

Bạn diễn, phim chung, đạo diễn-thể loại và đường liên hệ đều cần duyệt đồ thị (traversal) qua nhiều cạnh.

Mô hình phải phản ánh trực tiếp các quan hệ.

Giải thích được

Kết quả cần gắn với nguồn, thực thể đã liên kết, cạnh hỗ trợ và đóng góp điểm.

Không chấp nhận suy diễn hộp đen.

Đồ thị tri thức có thể tích hợp dữ liệu phim đa nguồn, hỗ trợ truy vấn nhiều bước và tạo kết quả có bằng chứng như thế nào?

01

Quy trình TMDB + IMDb tái lập được

02

Định danh ổn định và ràng buộc dữ liệu

03

Cypher nhiều bước và đường đi ngắn nhất

04

QA 9 ý định + gợi ý có lời giải thích

05

Đánh giá chất lượng, suy diễn và hiệu năng

Phạm vi được khóa để bảo đảm tính kiểm chứng

MVP tập trung vào đồ thị phim có thể chạy, đo và trình diễn; không mở rộng sang sinh Cypher tự do.

4.999

Phim (Movie) hợp lệ

từ 5.000 bản ghi đầu vào

5 + 1

Quan hệ gốc + suy diễn

CO_STARRED_WITH là cạnh suy ra

2 nguồn

TMDB + IMDb

IMDb chỉ enrich rating/votes

Trong phạm vi

Movie • Person • Genre • Keyword • Studio

Neo4j/Cypher • RDF/OWL/SPARQL

QA 9 ý định • gợi ý IDF có bằng chứng

Ngoài phạm vi

Giải thưởng/Wikidata • LLM-to-Cypher tự do

Tìm kiếm véc-tơ • GraphRAG • đa phương thức

Đánh giá người dùng quy mô lớn

Neo4j và RDF/OWL đảm nhiệm hai vai trò bổ trợ

Giá trị của đồ thị nằm ở mô hình quan hệ, đường đi bằng chứng và ngữ nghĩa — không phải luôn nhanh hơn SQL.

Yêu cầu	Mô hình bảng	Đồ thị thuộc tính
Quan hệ nhiều-nhiều	Bảng nối	Cạnh trực tiếp
Truy vấn nhiều bước	Chuỗi JOIN	Mẫu đường đi
Suy diễn co-star	Logic vật chất hóa riêng	Cạnh suy ra có bằng chứng
Giải thích	Dựng lại quan hệ	Đường đi tự nhiên

Neo4j / Cypher

Kho vận hành cho duyệt đồ thị, hỏi–đáp và gợi ý.

RDF / OWL / SPARQL


Lớp chuẩn trao đổi, ràng buộc và suy diễn ngữ nghĩa.

Kiến trúc đầu cuối: từ nguồn đến bằng chứng

Sau khi import, đường chạy trình diễn không phụ thuộc Internet.


KIẾN TRÚC TỔNG THỂ

Hai nhánh phục vụ: hỏi–đáp có kiểm soát và gợi ý phim có giải thích



Tích hợp IMDb theo chiến lược tiết kiệm lưu trữ

Chỉ đọc tuần tự tệp rating nén và ghép chính xác theo IMDb ID; không tải toàn bộ IMDb vào đồ thị.



4.558

Movie có IMDb ID

4.351

Rating ghép chính xác

95,5%


Tỷ lệ ghép trên IMDb ID

Không ghi đè

`rating`, `imdb\_rating` và `imdb\_votes` được giữ riêng.

Mô hình dữ liệu đặt định danh lên trước tên gọi

Một Person có thể vừa là diễn viên vừa là đạo diễn; vai trò được biểu diễn bằng quan hệ.



Định danh ổn định

`Person.person\_id = tmdb:<id>`
Tên không phải khóa chính.

Vai trò trên cạnh

`ACTED\_IN` giữ character, cast_order và source.


Ràng buộc

Ràng buộc (constraint) và chỉ mục được tạo trước khi nhập dữ liệu.

Nguồn chỉnh sửa: report_latex/images/sources/property_graph_schema.drawio

Quy trình dữ liệu có thể chạy lại và kiểm tra

Raw cache bất biến → dữ liệu chuẩn hóa tất định → import idempotent → validation.



Cache Không tải lại nguồn khi xử lý lại	Manifest Count + checksum + chất lượng	MERGE Import lặp không nhân bản	Gate Phát hiện orphan và khóa lỗi
---	--	---	---

Đồ thị cuối cùng vượt qua toàn bộ quality gate

Một bản ghi Movie không có quan hệ bị loại; ảnh chụp hợp lệ còn 4.999 phim.

76.612

Tổng số nút

846.309

Tổng số quan hệ

53.555

Person

12.509

Keyword

5.530

Studio

0

vi phạm cấu trúc



Orphan Movie



Stable ID trùng




Thiếu thuộc tính bắt buộc



Cạnh sai kiểu/đầu mút

Phân giải thực thể: exact trước, fuzzy có kiểm soát

Mục tiêu là tránh false positive; trường hợp mơ hồ có thể từ chối thay vì nối sai.



1,000

Precision

100 cặp silver

0,933

Recall

5 trường hợp abstain

0,966

F1

nearest-name hard negatives

Cypher biến câu hỏi quan hệ thành mẫu đường đi

Tham số người dùng được truyền riêng; cấu trúc truy vấn lấy từ danh mục cố định.

```
MATCH (d:Person)-[:DIRECTED]->(m:Movie)
      -[:HAS_GENRE]->(g:Genre)
WHERE g.name = $genre
RETURN d.name, count(m) AS movie_count
ORDER BY movie_count DESC
LIMIT $limit
```

`$genre` · `$limit`

1

Tra cứu

Phim theo đạo diễn · diễn viên theo phim

2

Nhiều bước (multi-hop)

Phim chung · đạo diễn → phim → thể loại

3

Đường đi và suy diễn

`shortestPath([*..8]) · CO_STARRED_WITH`


✓

An toàn

Không để chuỗi đầu vào vào Cypher.

CO_STARRED_WITH là fact suy ra có thể kiểm chứng

Không gọi đây là OWL reasoning: đây là phép vật chất hóa luật nghiệp vụ bằng Cypher.



Sự kiện được khẳng định

ACTED_IN đến từ danh sách vai diễn của TMDB.

Sự kiện suy ra

CO_STARRED_WITH được tạo từ phim chung.


Bằng chứng

movie_count · evidence_movie_ids · derived=true

Nguồn chỉnh sửa: report_latex/images/sources/costar_reasoning.drawio

Giá trị của chatbot nằm ở việc điều phối Cypher an toàn

Ngôn ngữ tự nhiên chọn ý định và thực thể; Neo4j thực hiện traversal và trả bằng chứng.



9 ý định cố định

Tra cứu · tổng hợp · nhiều bước · đường đi ngắn nhất

Liên kết thực thể

"Cristopher Nolan" → Christopher Nolan + độ tin cậy

Bằng chứng đồ thị

Ý định · thực thể · bản ghi/đường đi · độ trễ

Gợi ý giải thích được bằng đóng góp trên đồ thị

IDF giảm ảnh hưởng của đặc trưng quá phổ biến; mỗi đề xuất kèm các đặc trưng chung tạo điểm.



$\text{contribution} = \text{type_weight} \times (1 + \ln((N+1)/(df+1)))$

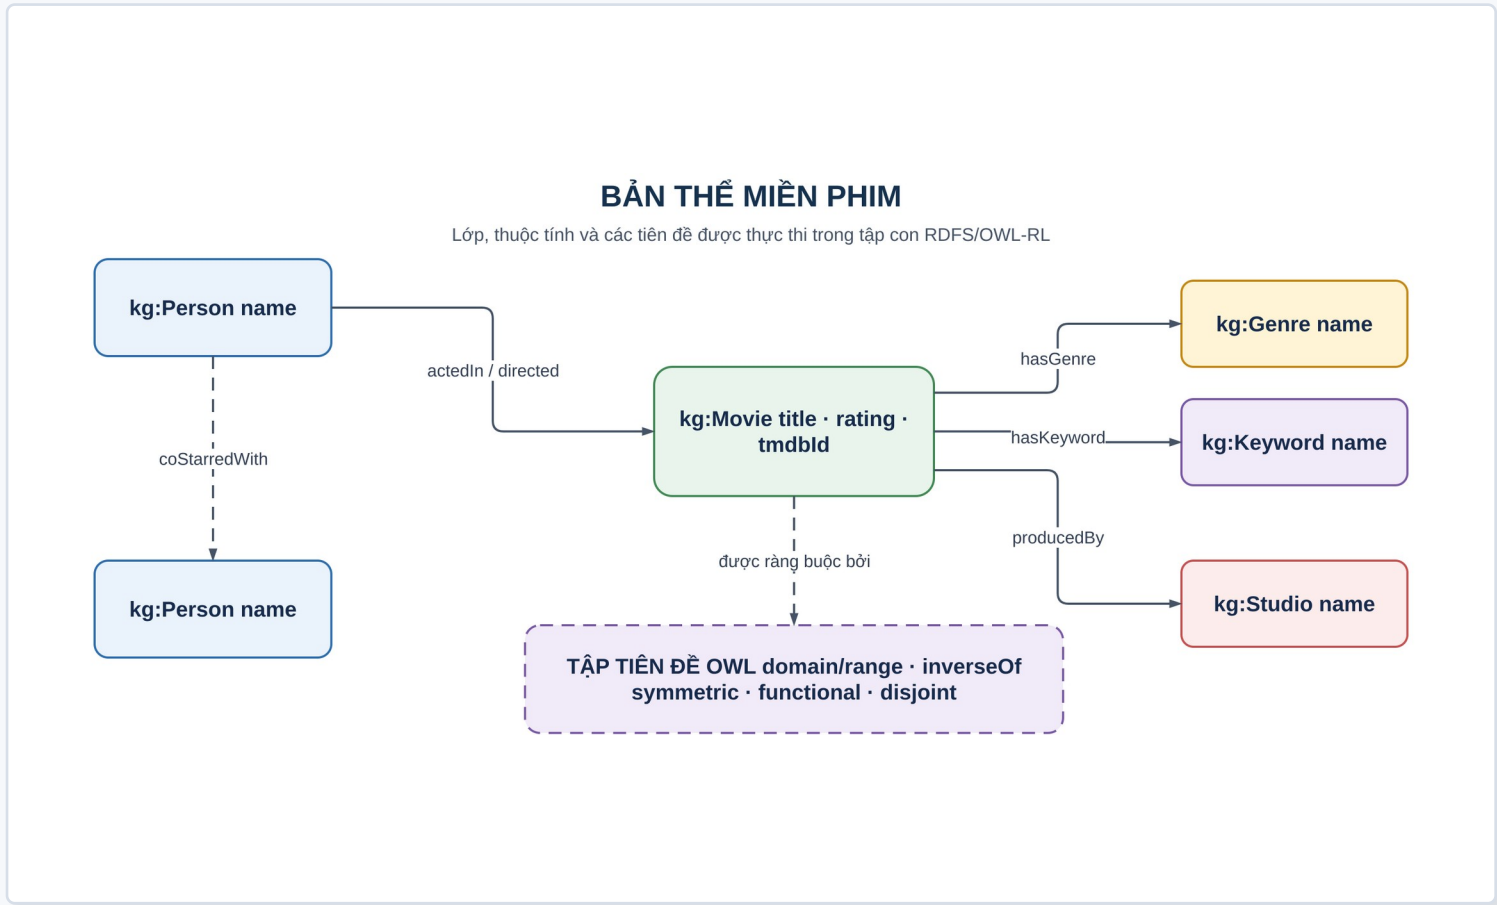


Điểm được tính trong Neo4j
Không tải toàn bộ graph về Python.

Nguồn chỉnh sửa: report_latex/images/sources/recommendation_explanation.drawio

RDF/OWL bổ sung lớp chuẩn ngữ nghĩa

Cùng ảnh chụp dữ liệu được xuất sang Turtle với URI ổn định và truy vấn bằng SPARQL.



1 Khả năng liên thông

URI ổn định và từ vựng chuẩn hóa.

2 Ràng buộc

Functional property · disjoint class · required title.

3 Suy diễn ngữ nghĩa

miền/phạm vi · inverseOf · quan hệ đối xứng.

10/10 SPARQL

RDFLib và Jena/Fuseki.

Suy diễn ngữ nghĩa đã chạy trên toàn ảnh chụp

Kết quả chỉ đại diện cho RDFS/OWL-RL subset đã khai báo, không phải full OWL 2 DL.

SUY DIỄN NGỮ NGHĨA CÓ THỂ KIỂM CHỨNG

Cùng tập luật được đánh giá bằng RDFLib và Apache Jena/Fuseki



342.683

Triple trước

429.192

Triple sau

+86.509

Triple suy ra

0

Vi phạm ngữ nghĩa

Hai loại suy diễn

OWL entailment cho semantics; Cypher rule cho CO_STARRED_WITH.

Đánh giá được thiết kế theo từng tuyên bố

Mỗi metric gắn với dataset, protocol và giới hạn diễn giải cụ thể.

Hạng mục	Tập đánh giá	Metric
Chất lượng dữ liệu	Toàn corpus	missing · duplicate · orphan
Phân giải thực thể	100 cặp silver	P · R · F1
Suy diễn co-star	50 fact silver	precision
Hỏi–đáp	20 câu smoke	accuracy + evidence
Gợi ý	20 case silver	P@10 · NDCG@10
Hiệu năng	4 quy mô × 4 query	median · p95 · 100 lần

Silver ≠ ground truth độc lập

Corpus được sinh tất định, có provenance và rubric công bố.

So sánh công bằng

Neo4j và SQLite dùng cùng snapshot, máy, warm-up và số lần chạy.

Không vượt quá bằng chứng

Không suy rộng sang concurrency, cold cache hay production scale.

Kết quả chính: đúng cấu trúc, có bằng chứng, còn dư địa cải thiện

Các con số dưới đây đều thuộc lần chạy 5.000 đầu vào ngày 24/07/2026.

20/20

QA smoke

Neo4j + evidence

0,966

Entity F1

100 cặp silver

1,00

Co-star precision

50 fact silver

0,635


Recommendation P@10

20 case silver

0,672

NDCG@10

20 case silver





Cách đọc thận trọng

- QA là smoke corpus được quản lý.
- Entity precision cao nhờ abstention bảo thủ.
- Recommendation là metric silver, chưa phải đánh giá người dùng.
- Mọi output gợi ý đều có đường giải thích.

Nguồn: experiments/results/summary/quality_metrics.csv

Phép đo so sánh cho thấy sự đánh đổi

SQLite nhanh hơn ở toàn bộ cặp truy vấn/quy mô; Neo4j đổi lại mô hình duyệt đồ thị và bằng chứng trực tiếp.



Kết luận hiệu năng


Đo warm-cache, 100 lần/query, không đo concurrency hoặc cold cache.

Kết luận gợi ý

Các mốc cũ là lịch sử thiết kế, không phải lựa chọn runtime.

Nguồn: multiscale_benchmark.csv · recommendation_ablation.json · recommendation.json

Từ câu hỏi tự nhiên đến đường đi bằng chứng



Giới hạn được xem là một phần của kết quả

Các kết luận chỉ có giá trị trong ảnh chụp dữ liệu và protocol đã công bố.



Đồ thị tri thức tạo giá trị khi mỗi quan hệ đều có thể được kiểm chứng

01

Tích hợp đúng

TMDB + IMDb, stable ID, provenance và quy trình tái lập.

02

Truy vấn được

Cypher multi-hop, derived fact và semantic entailment.

03

Giải thích được

QA và gợi ý trả cả thực thể, path và đóng góp điểm.

Xin cảm ơn thầy. Em xin lắng nghe câu hỏi và phản biện.

Phụ lục • Chính ý định và nhóm Cypher

Chỉ mở khi giảng viên hỏi sâu về phạm vi chatbot.

1 movies_by_director

Lookup 1-2 hop

2 actors_in_movie

Lookup 1 hop

3 common_movies

Shared neighbor

4 movies_by_genre_rating

Filter + traversal

5 co_stars

Derived edge

6 directors_by_genre

Aggregation 2 hop

7 shortest_path

shortestPath([*..8])

8 similar_movies

Graph similarity

9 movie_details

Canonical lookup

Bảng giới hạn toàn

Parser chỉ chọn intent và tham số; cấu trúc Cypher luôn lấy từ catalog cố định.

Phụ lục • Hai lớp suy diễn không bị đánh đồng

OWL entailment phục vụ ngữ nghĩa; Cypher materialization phục vụ luật nghiệp vụ.

RDFS / OWL-RL subset

domain / range → suy ra kiểu
inverseOf → actedIn $\rightleftharpoons$ hasActor
symmetric property
functional/disjoint validation

342.683 → 429.192 triple
+86.509 inferred • 0 violation

Cypher rule nghiệp vụ

Person A → Movie ← Person B

Vật chất hóa CO_STARRED_WITH
movie_count
evidence_movie_ids
derived=true

Precision silver: 1,00 / 50 fact